

Universidad Nacional Autónoma de México
Facultad de Ciencias

Licenciatura en Ciencias de la Computación

Asignatura: Almacenes y Minería de Datos

Práctica 3: Polars

Reporte de práctica

Integrantes del Equipo:

Nombre	Número de Cuenta
Vega Navas Saúl	322088267
Cimmino Yáñez Nicholas Joseph	322490712
Benítez Pérez Kristian Leonel	322011346
Herrera Cuamatla Jennifer Jade	322255481

Fecha de entrega: Lunes 21 de septiembre del 2026

1. Comparación de los frameworks

Nosotros elegimos el framework Polars ya que fue el recomendado, aparte, al ver que íbamos a trabajar con el dataset de la ENDIREH del gobierno mexicano, en donde aunque no son muchísimos datos, es más rápido que trabajar con pandas. Pandas se utilizaría para bases de datos pequeñas-medianas, y con PySpark, aunque es uno de los estándares de la industria no lo utilizamos principalmente porque está diseñado para manejar grandes volúmenes de datos utilizando computación distribuida. Nosotros no necesitamos tanto, ya que nuestra base de datos es de tamaño no tan grande pero no tan pequeña, por lo tanto Polars se nos hizo la opción más adecuada para esta práctica.

2. Documentación del preprocesamiento

Una de las partes más complejas de la práctica fue decidir hacer un buen procesamiento y de hecho hubo varias confusiones en el proceso que hizo que tuviéramos que modificar las decisiones del mismo. El pipeline para el preprocesamiento de los datos es el siguiente: normalizar -¿quitar_nulos -¿agregar_variables. Básicamente con normalizar, normalizábamos cada una de las columnas, transformándolas a enteros si es posible, en tablas donde en cada fila aparecía un número, es más probable que la tabla realmente sea de números, las variables cualitativas simplemente les hicimos un lowercase y listo. Con quitar nulos no fue nada sencillo, pues tuvimos que tomar diferentes decisiones ya que había columnas con muchos nulos y otras sin ningún nulo. Notamos en el archivo crudo que muchos datos faltantes eran básicamente porque les faltaba el contexto de otra variable, por lo que sabiendo el contexto supimos como hacer para cada variable. La decisión final sobre el quitar nulos, fue que si tenía más del 3 % de nulos entonces se iban a poner datos que coincidieran con los demás valores, y si tenía menos del 3 % entonces esas filas se eliminaban. Ahora en el preprocesamiento agregamos dos nuevas variables, para tener información extra sobre los datos obtenidos y crudos. También dentro de quitar_nulos nos aseguramos que si una variable tenía un mismo valor para todas las filas, entonces esta columna sería removida.

Sobre los duplicados, revisamos el dataset ya limpio y encontramos filas con los mismos valores en las columnas que conservamos (alrededor de 3,500 combinaciones repetidas, unas 7,900 filas en total). Decidimos no eliminarlas, ya que al haber reducido el archivo original a únicamente las 24 columnas de interés para la práctica, es esperable que distintas mujeres encuestadas coincidan exactamente en entidad, escolaridad, número de hijos y demás variables sin ser en realidad el mismo registro; el dataset no cuenta con un identificador único por encuestada que nos permita confirmar si se trata de una duplicidad real, por lo que eliminarlas hubiera significado perder observaciones válidas.

3. Tabla de clasificación de variables

Variable	Tipo de dato	Justificación
edad_primer_union	Cuantitativa	Representa el año en el que la mujer tuvo al unirse por primera vez. Es numérico y entero
num_hijos	Cuantitativa	Representa cuantos hijos tiene la mujer. Es un número entero y numérico.

Variable	Tipo de dato	Justificación
nivel_escolaridad	Cualitativa Ordinal	Representa el nivel de escolaridad que tiene la mujer, en una escala de 'A1', 'A2', 'B1', 'B2', 'C1', 'C2' con una relación de orden entre letras y números.
nom_entidad	Cualitativa Nominal	Representa la entidad federativa en donde reside la mujer.
nom_municipio	Cualitativa Nominal	Representa el municipio de la entidad federativa donde reside la mujer.
estado_civil_desc	Cualitativa Nominal	Representa el estado civil de la mujer
estrato_socioeconomico	Cualitativa Ordinal	Aunque se represente numéricamente, se trata de diferentes estados económicos con orden entre si
pareja_trabaja_desc	Cualitativa Nominal	Describe si la pareja trabaja o no
ingreso_pareja	Cuantitativa	Cantidad numérica que recibe la pareja de la mujer
dinero_propio_desc	Cualitativa Nominal	Describe si tiene dinero propio o no, la mujer
apoyo_gobierno_desc	Cualitativa Nominal	Describe si tiene apoyo del gobierno o no, la mujer
tiene_ahorros_desc	Cualitativa Nominal	Describe si la mujer tiene ahorros o no
propietaria_vivienda_desc	Cualitativa Nominal	Describe si la mujer es propietaria de la vivienda
sufrio_violencia_pareja	Cualitativa Nominal	Describe si la mujer ha sufrido violencia de pareja
factor_expansion	Cuantitativa	Es un peso estadístico calculado por el INEGI que es numérico. Indica a cuántas mujeres reales representa cada fila de la muestra.
autonomia_financiera	Cualitativa Ordinal	Representa con los identificadores de 'baja', 'media', 'alta', la autonomía financiera de la mujer

Variable	Tipo de dato	Justificación
bloque_educativo	Cualitativa Ordinal	Representa en que bloque educativo se encuentra la mujer

4. Resultados de medidas de localización y de variabilidad

4.1. Medidas de localización

4.1.1. Cálculo de medidas de tendencia central de edad_primer_union

- Media: 10.026312
- Mediana: 6.0
- Moda: 0.0
- P10: 0.0
- Q1: 2.0
- Q2: 6.0
- Q3: 15.0
- P90: 25.0

4.1.2. Cálculo de medidas de tendencia central de num_hijos

- Media: 2.523377
- Mediana: 3.0
- Moda: 3.0
- P10: 1.0
- Q1: 1.0
- Q2: 3.0
- Q3: 3.0
- P90: 4.0

4.2. Calculo de media ponderada

La media ponderada de la edad de la primera union es: 9.70018864220801

La media ponderada de el número de hijos es: 2.4547020204219776

4.3. Relación entre media ponderada y media

Podemos ver que la media ponderada de la edad de la primera unión coincide con la media con una diferencia de 0.3. La media ponderada del número de hijos también coincide, sin embargo hay una diferencia de aproximadamente 0.1, lo cuál está bien. Lo que significa que nuestra muestra es relativamente cercana la población en general y no presenta desvíos muy grandes.

4.4. Medidas de variabilidad

Además de las medidas de localización, calculamos las medidas de variabilidad de las mismas dos variables cuantitativas, separando a las mujeres encuestadas en dos grupos según la variable `sufrio_violencia_pareja` (0 = no sufrió, 1 = sí sufrió), para poder comparar la dispersión entre ambos grupos.

4.4.1. Variabilidad de `edad_primer_union`

- **Grupo sin violencia de pareja (n = 15210):** Rango: 76.0, Varianza: 117.334875, Desviación estándar: 10.832122, IQR: 13.0, CV: 108.03 %
- **Grupo con violencia de pareja (n = 8467):** Rango: 72.0, Varianza: 110.523091, Desviación estándar: 10.512996, IQR: 13.0, CV: 104.86 %

4.4.2. Variabilidad de `num_hijos`

- **Grupo sin violencia de pareja (n = 15210):** Rango: 3.0, Varianza: 1.371631, Desviación estándar: 1.171167, IQR: 2.0, CV: 46.15 %
- **Grupo con violencia de pareja (n = 8467):** Rango: 3.0, Varianza: 1.488155, Desviación estándar: 1.219899, IQR: 3.0, CV: 48.83 %


4.4.3. Interpretación

En `edad_primer_union` el grupo que reportó violencia de pareja presenta, en realidad, un coeficiente de variación ligeramente menor (104.86 %) que el grupo que no la reportó (108.03 %), por lo que en nuestros datos no se cumple la premisa de que la dispersión sea considerablemente más alta en el grupo con violencia; ambos grupos muestran una dispersión relativa muy alta y del mismo orden. En `num_hijos` ocurre algo similar: el CV es apenas un poco mayor en el grupo con violencia (48.83 % contra 46.15 %), una diferencia pequeña que no sugiere un comportamiento marcadamente distinto entre ambos grupos.

5. EDA

Para el análisis exploratorio se utilizaron las bibliotecas `matplotlib` y `seaborn` para las gráficas, y `numpy` como apoyo en el cálculo numérico. Antes de graficar se exploró el dataset (110,127 filas y 24 columnas antes del preprocesamiento) para confirmar los nombres, tipos y contenido de las columnas, lo cual sirvió de base para la clasificación de variables presentada en la Sección 3.

5.1. Violencia de pareja por entidad federativa



Podemos ver que el estado en donde más hay violencia de pareja a mujeres, es el estado de Guerrero, con más de un 22 %. Como se menciona en la primera pregunta del cuestionario, este tipo de resultados hay que interpretarlos con cuidado: señalan en qué entidades el fenómeno se reporta con mayor frecuencia en la muestra, pero no deben leerse como que en esos estados las mujeres o sus parejas sean distintas por naturaleza, sino que abren la puerta a investigar qué factores socioeconómicos, culturales o de acceso a denuncia están detrás de esa diferencia regional.

6. Cuestionario

1. Al tratarse de un tema social sensible como la violencia contra las mujeres, ¿qué consideraciones éticas debe tener el equipo de análisis al interpretar y presentar los resultados del EDA?

Al ser analizados los datos sobre violencia contra las mujeres en el EDA, como equipo debemos mantener las siguientes consideraciones éticas:

- Evitar la revictimización y estigmatizar: Al interpretar los datos considerando los factores que forman al problema, no habrá que buscar culpables en las víctimas ni reforzar ningún tipo de estereotipo de género o prejuicios así como evitar generalizar.

Por lo que es importante tomar un lenguaje adecuado y no generalizador ante este análisis.

- Presentar datos o gráficas aisladas sin el debido contexto metodológico; ya sea omitir los factores de expansión o ignorar el diseño muestral, puede conducir a conclusiones erróneas o alarmantes que distorsionen la realidad del fenómeno social.

- También hay que reconocer que la violencia no afecta a todas las mujeres de la misma manera. Este análisis debe contemplar cómo interactúan variables socioeconómicas, escolaridad, edad o entidad federativa para poder entender la complejidad del problema sin caer en determinismos.
 - El procesamiento de datos debe realizarse de la mejor manera para garantizar que los resultados reflejen con fidelidad la realidad capturada por la encuesta, asegurando transparencia en las limitaciones del dataset.
2. Se calculó la media simple de edad primer union y también la media ponderada por factor expansión. ¿Por qué pueden diferir ambos valores, y cuál de las dos es más representativa de la población nacional de mujeres de 15 años y más?

Los valores pueden diferir porque en la encuesta la **media simple** asume que todas las mujeres encuestadas tiene el valor de 1 es decir, 1 persona = 1 voto. Y la **media ponderada** multiplica cada respuesta por su **factor_expansion** porque en otras encuestas como las que realiza INEGI dado que es a grandes masas; una sola mujer puede representar a 500 0 1000 mujeres de su ciudad o estado o municipio.

La más representativa es la media ponderada ya que refleja la realidad del país ajustándose a cada región y ajusta la muestra para poder representar a todas las mujeres de 15 años en México.

3. Si el coeficiente de variación de edad-primer-union resulta considerablemente más alto en el grupo que reportó violencia de pareja que en el que no, ¿qué hipótesis plantearíamos para explicarlo, y qué otra variable del dataset ayudaría a confirmar o descartar?

Si la situación es verdadera, entonces podemos plantear una hipótesis sobre la distribución, declarando que la concentración de situaciones de violencia de pareja no se da hacia un rango de edades concreto, sino que puede ser una mezcla entre las edades consideradas como tempranas, por causas derivadas de la alta vulnerabilidad de esos sectores; y las consideradas como comunes, por causas diferentes a las primeras mencionadas.

Esto se puede respaldar o refutar con factores como `estrato_socioeconomico` y `nivel_escolaridad`, pudiendo confirmar si las uniones a edades tempranas se asocian con situaciones de bajos recursos y baja escolaridad que derivan en los escenarios de vulnerabilidad planteados en la hipótesis, o si, por el contrario, dichos valores tienen baja heterogeneidad a lo largo del intervalo de edades.

4. Compara la media simple de edad_primer_union contra la media ponderada por factor_expansion. ¿Por qué pueden diferir? ¿Cuál de las dos debería reportarse si el objetivo es describir a la población nacional y no solo a la muestra encuestada?

Las cifras difieren porque la media simple asume erróneamente que cada persona en la base de datos tiene exactamente la misma probabilidad de haber sido encuestada, lo que hace que todos los registros tengan la misma validez; no obstante, el factor de expansión añade valores de importancia para abarcar los efectos del encapsulamiento de sectores poblacionales completos en representaciones que, sin dicho factor, se consideran para una única persona.

Es por esto que, al buscar describir no solo al conjunto de personas entrevistadas, sino a la población nacional, se debe reportar la media ponderada, pues las canti-

dades de personas que ésta engloba permite generalizar los resultados para reflejar estadísticamente al país completo.

5. Si el coeficiente de variación de edad-primer-union resulta considerablemente más alto en el grupo que reportó violencia de pareja que en el que no, ¿qué hipótesis plantearíamos para explicarlo, y qué otra variable del dataset ayudaría a confirmar o descartar?

Si la situación es verdadera, entonces podemos plantear una hipótesis sobre la distribución, declarando que la concentración de situaciones de violencia de pareja no se da hacia un rango de edades concreto, sino que puede ser una mezcla entre las edades consideradas como tempranas, por causas derivadas de la alta vulnerabilidad de esos sectores; y las consideradas como comunes, por causas diferentes a las primeras mencionadas.

Esto se puede respaldar o refutar con factores como `estrato_socioeconomico` y `nivel_escolaridad`, pudiendo confirmar si las uniones a edades tempranas se asocian con situaciones de bajos recursos y baja escolaridad que derivan en los escenarios de vulnerabilidad planteados en la hipótesis, o si, por el contrario, dichos valores tienen baja heterogeneidad a lo largo del intervalo de edades.